

تخمین پارامترهای مدل

$$P(D|\theta) = P(\{A_i\}_{i=1}^N | \theta) = \prod_{i=1}^N P(A_i | \theta)$$

$$= \prod_{i=1}^N \prod_{c=1}^4 \theta_c^{a_{ic}}, \quad A_i \rightarrow \text{one-hot بردار گذشت}$$

برای به دست آوردن $\hat{\theta}_{MLE}$ ، $NLL(\theta)$ را گسل می دهیم.

$$NLL(\theta) = -\log \prod_{i=1}^N \prod_{c=1}^4 \theta_c^{a_{ic}} = -\sum_{i=1}^N \sum_{c=1}^4 a_{ic} \log \theta_c$$

حال مسأله بهینه سازی زیر را داریم:

$$\begin{aligned} \min_{\theta} \quad & NLL(\theta) \\ \text{s.t.} \quad & \sum_{c=1}^4 \theta_c = 1 \end{aligned}$$

$$L = -\sum_{i=1}^N \sum_{c=1}^4 a_{ic} \log \theta_c + \lambda \left(\sum_{c=1}^4 \theta_c - 1 \right)$$

$$\frac{\partial L}{\partial \theta_k} = -\sum_{i=1}^N \sum_{c=1}^4 a_{ic} \frac{\frac{1}{\theta_k} \delta_{kc}}{\frac{\partial \log \theta_c}{\partial \theta_k}} + \lambda \left(\sum_{c=1}^4 \frac{\partial \theta_c}{\partial \theta_k} - 1 \right)$$

$$= -\sum_{i=1}^N \frac{a_{ik}}{\theta_k} + \lambda = 0 \Rightarrow \theta_k = \frac{\sum_{i=1}^N a_{ik}}{\lambda}$$

$$\frac{\partial L}{\partial \lambda} = 0 \Rightarrow \sum_{c=1}^4 \theta_c = 1 \Rightarrow \sum_{c=1}^4 \frac{\sum_{i=1}^N a_{ic}}{\lambda} = 1 \Rightarrow \frac{N}{\lambda} = 1 \Rightarrow \lambda = N$$

$$\Rightarrow \theta_k = \frac{\sum_{i=1}^N a_{ik}}{N}, \quad k=1, 2, 3, 4$$

$$P(\theta|D) = \frac{P(D|\theta) P(\theta)}{P(D)}$$

ب:

$$= \frac{\prod_{j=1}^N \prod_{c=1}^4 \theta_i^{\alpha_{ic}} \frac{1}{B(\alpha)} \prod_{j=1}^4 \theta_j^{\alpha_j-1}}{P(D)}$$

$$= \frac{\frac{1}{B(\alpha)} \prod_{c=1}^4 \theta_i^{N_i} \prod_{j=1}^4 \theta_j^{\alpha_j-1}}{P(D)}$$

$$= \frac{1}{B(\alpha)P(D)} \prod_{c=1}^4 \theta_c^{(N_c + \alpha_c - 1)} \sim \text{Dir}(\alpha + m)$$

$$, m = \begin{bmatrix} N_1 \\ N_2 \\ \vdots \\ N_4 \end{bmatrix}$$

بر اساس مشخصات توزیع دیریکله می دانیم:

$$\text{Mode}[X_i] = \frac{\alpha_i - 1}{\alpha_0 - k}$$

در توزیع دیریکله داریم:

$$\hat{\theta}_{\text{map}} = \begin{bmatrix} \frac{\alpha_1 + N_1 - 1}{\alpha_0 + N - 4} \\ \vdots \\ \frac{\alpha_4 + N_4 - 1}{\alpha_0 + N - 4} \end{bmatrix}, \alpha_0 = \sum_{i=1}^4 \alpha_i$$

ج: یک توزیع دیریکله $\hat{\theta}_{\text{map}}$ خواسته شد، ایجاد می کند برابر است با:

$$\alpha = \begin{bmatrix} 1 \\ \checkmark \\ \checkmark \\ \checkmark \\ \checkmark \\ \checkmark \end{bmatrix} \Rightarrow \hat{\theta}_{\text{map}} = \begin{bmatrix} 1/4 \\ 1/4 \\ 1/4 \\ 1/4 \\ 1/4 \\ 1/4 \end{bmatrix}$$

$$E_{p(y|x)}[l(a=-1, y)] = \sum_{y_i \in \{\pm 1\}} p(y_i|x) l(a=-1, y_i) \quad (\text{الف})$$

$$= P_0 \lambda_e + (1-P_0) \cdot 0 = P_0 \lambda_e$$

$$E_{p(y|x)}[l(a=+1, y)] = \sum_{y_i \in \{\pm 1\}} p(y_i|x) l(a=+1, y_i)$$

$$= P_0 \cdot 0 + (1-P_0) \lambda_e = (1-P_0) \lambda_e$$

$$E_{p(y|x)}[l(a=0, y)] = \sum_{y_i \in \{\pm 1\}} p(y_i|x) l(a=0, y_i)$$

$$= P_0 \lambda_r + (1-P_0) \lambda_r = \lambda_r$$

$$a^* = \begin{cases} +1 & \begin{cases} (1-P_0) \lambda_e \leq P_0 \lambda_e \Rightarrow P_0 \geq \frac{1}{2} \\ (1-P_0) \lambda_e \leq \lambda_r \Rightarrow P_0 \geq 1 - \frac{\lambda_r}{\lambda_e} \end{cases} \\ -1 & \begin{cases} P_0 \lambda_e \leq (1-P_0) \lambda_e \Rightarrow P_0 \leq \frac{1}{2} \\ P_0 \lambda_e \leq \lambda_r \Rightarrow P_0 \leq \frac{\lambda_r}{\lambda_e} \end{cases} \\ 0 & \text{otherwise} \end{cases} \quad (\text{ب})$$

$$\Rightarrow a^* = \begin{cases} +1 & P_0 \geq \max\left\{\frac{1}{2}, 1 - \frac{\lambda_r}{\lambda_e}\right\} \\ -1 & P_0 \leq \min\left\{\frac{1}{2}, \frac{\lambda_r}{\lambda_e}\right\} \\ 0 & \text{otherwise} \end{cases}$$

مشتق گیری نسبت به پارامترها :

$$NLL(W) = - \sum_{c=1}^C y_c \log \mu_c$$

نویسند $W = \begin{bmatrix} \hat{w}_1^T \\ \vdots \\ \hat{w}_C^T \end{bmatrix}$ در انصورت

$$\frac{\partial NLL(W)}{\partial \hat{w}_j} = \frac{\partial}{\partial \hat{w}_j} \left(- \sum_c y_c \log \mu_c \right) = - \sum_c y_c \underbrace{\frac{\partial}{\partial \hat{w}_j} \log \mu_c}_{= \frac{\partial}{\partial \mu_c} \log \mu_c \times \frac{\partial \mu_c}{\partial \hat{w}_j}}$$

$$= - \sum_c \frac{y_c}{\mu_c} \frac{\partial \mu_c}{\partial \hat{w}_j} \quad (1)$$

حال $\frac{\partial \mu_c}{\partial \hat{w}_j}$ را بدست می آوریم :

$$\frac{\partial \mu_c}{\partial \hat{w}_j} = \sum_k \frac{\partial \mu_c}{\partial a_k} \frac{\partial a_k}{\partial \hat{w}_j} = \frac{\partial \mu_c}{\partial a_j} x \quad (2)$$

حال $\frac{\partial \mu_c}{\partial a_j}$ را بدست می آوریم :

$$\frac{\partial \mu_c}{\partial a_j} = \begin{cases} \frac{\partial}{\partial a_j} \frac{\exp(a_j)}{\sum_k \exp(a_k)} = \mu_j (1 - \mu_j) = \mu_c (1 - \mu_j) & j=c \\ \frac{\partial}{\partial a_j} \frac{\exp(a_c)}{\sum_k \exp(a_k)} = - \mu_c \mu_j & j \neq c \end{cases}$$

$$= \mu_c (\delta_{jc} - \mu_j) \quad (3)$$

با استفاده از ۱، ۲، ۳ :

$$\begin{aligned} \frac{\partial NLL(W)}{\partial \hat{w}_j} &= - \sum_c \frac{y_c}{\mu_c} x \mu_c (\delta_{jc} - \mu_j) \\ &= - x \left(\sum_c y_c \delta_{jc} - \sum_c y_c \mu_j \right) = x (\mu_j - y_j) \end{aligned}$$

حال اگر رابطه را برای تمام سطرها تکرار کنیم، داریم:

$$\frac{\partial L(W)}{\partial W} = \begin{bmatrix} (\mu_1 - y_1)x \\ \vdots \\ (\mu_C - y_C)x \end{bmatrix} = (\mu - y)^T x \in \mathbb{R}^{C \times D}$$

رگرسیون لاگستیک باینری

$$P(D|w) = \prod_{n=1}^N \text{Ber}(y_n | \mu_n) = \prod_{n=1}^N \mu_n^{y_n} (1-\mu_n)^{1-y_n} \quad (الف)$$

$$\Rightarrow -\log P(D|w) = -\sum_{n=1}^N [y_n \log \mu_n + (1-y_n) \log (1-\mu_n)]$$

ب) برای جداپذیری خطی بودن لازم است:

$$\begin{cases} a_n > 0 & \text{if } y_n = 1 \\ a_n < 0 & \text{if } y_n = 0 \end{cases} \equiv \begin{cases} \mu_n > \frac{1}{2} & y_n = 1 \\ \mu_n < \frac{1}{2} & y_n = 0 \end{cases}$$

در شرایط فوق تمام داده‌های باید. دار. درست طبقه‌بندی شود، چون منطبق‌پذیری در رگرسیون لاگستیک باینری، خطی است. در این شرایط مسأله جداپذیری خطی خواهد بود.

ج) فرض کنید $\tilde{w}$ شرط جداپذیری خطی را دارد. حال بردار $\hat{w} = g \tilde{w}$ را در نظر بگیرید. بردار $\alpha_k = 1$ را در نظر بگیرید. چون $\tilde{w}$ شرط جداپذیری را دارد بنابراین $\tilde{\alpha}_k > 0$ در نتیجه:

$$\hat{\alpha}_k = \hat{w}^T x = g \tilde{w}^T x = g \tilde{\alpha}_k > \tilde{\alpha}_k \stackrel{(*)}{\Rightarrow} \sigma(g \tilde{\alpha}_k) > \sigma(\tilde{\alpha}_k)$$

$$\Rightarrow \hat{\mu}_k > \tilde{\mu}_k \Rightarrow -[y_n \log \hat{\mu}_k + (1-y_n) \log (1-\hat{\mu}_k)] > -[y_n \log \tilde{\mu}_k + (1-y_n) \log (1-\tilde{\mu}_k)]$$

به طور مشابه برای نمونه‌های $y_k = 0$ نیز می‌توان نشان داد رابطه فوق برقرار است پس:

$$-\sum_{n=1}^N [y_n \log \hat{\mu}_n + (1-y_n) \log (1-\hat{\mu}_n)] \leq -\sum_{n=1}^N [y_n \log \tilde{\mu}_n + (1-y_n) \log (1-\tilde{\mu}_n)]$$

$$\Rightarrow NLL(\hat{w}) \leq NLL(\tilde{w})$$