



باسمه تعالی

دانشگاه صنعتی شریف

دانشکده مهندسی برق

مقدمه‌ای بر یادگیری ماشین - گروه ۳

۱۰ دی ماه ۱۴۰۱

آزمون میان ترم

۱. مدت زمان پاسخ‌گویی به سوالات ۹۰ دقیقه است. آزمون ساعت ۱۵ شروع و در ساعت ۱۶:۳۰ خاتمه خواهد یافت.
۲. هر فرد مجاز به استفاده از یک برگه A۴ پشت‌رو فرمول است. این برگه شخصی بوده دانشجویان نمی‌توانند در حین آزمون از برگه فرد دیگری استفاده نمایند.
۳. در انتهای آزمون هر فرد می‌بایست پاسخ‌برگ، برگه سوالات را تحویل دهد.

با آرزوی موفقیت

۱ تخمین پارامترهای مدل

متغیر تصادفی A را به عنوان نتیجه پرتاب یک تاس شش وجهی در نظر بگیرید. فضای مشاهدات این متغیر تصادفی مجموعه گسسته $\{1, 2, 3, 4, 5, 6\}$ است. متغیر تصادفی A دارای توزیع رسته‌ای (Categorical Distribution) $A \sim \text{Cat}(\theta)$ است. حال فرض کنید N رخداد هم‌توزیع مستقل (independently and identically distributed) از متغیر تصادفی را مشاهده نموده‌اید که آن را با پایگاه داده $\mathcal{D} = \{A_i\}_{i=1}^N$ نمایش می‌دهیم.

الف: درست‌نمایی پایگاه داده $\mathcal{D}$ را بر حسب بردار θ ($p(\mathcal{D}|\theta)$) به دست آورید و تخمین بیشینه درست‌نمایی $\hat{\theta}_{mle}$ را تعیین نمایید (راهنمایی: $\text{NLL}(\theta)$ را به دست آورده، لاگرانژین را ساخته و برداری که مشتق آن را صفر می‌کند، تعیین نمایید).

ب: فرض کنید بردار θ دارای توزیع دیرپچله $\theta \sim \text{Dir}(\alpha)$ باشد ($\alpha_i > 1$). نشان دهید توزیع پسین θ بعد از مشاهده پایگاه داده $\mathcal{D}$ ($p(\theta|\mathcal{D})$) دیرپچله با پارامتر $\hat{\alpha}$ است. $\hat{\alpha}$ را به دست آورید و تخمین بیشینه توزیع پسین $\hat{\theta}_{map}$ را تعیین نمایید.

ج: برای یک تاس بدون بایاس، فرض کنید پایگاه داده $\mathcal{D} = \{1, 1, 1, 1, 1, 1\}$ را مشاهده نموده‌اید. برای این تاس توزیع پیشین را به گونه‌ای تعیین نمایید که $\hat{\theta}_{map} = [\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}]$ گردد.

۲ تئوری تصمیم‌گیری

فرض کنید خروجی مدل $p(y|\mathbf{x})$ را در اختیار شما قرار داده است که $\mathcal{Y} = \{-1, +1\}$ است و شما می‌توانید یکی از سه تصمیم $\mathcal{A} = \{-1, 0, +1\}$ را بگیرید ($a = 0$ معادل با عدم تصمیم‌گیری است). تابع تلفات تصمیم‌گیری $\ell(a, y)$ به صورت زیر تعریف شده است:

$y = +1$	$y = -1$	
λ_e	0	$a = -1$
0	λ_e	$a = +1$
λ_r	λ_r	$a = 0$

همچنین فرض کنید $p(y = +1|\mathbf{x}) = p_0$ و تابع امید ریاضی تلفات $\mathbb{E}_{p(y|\mathbf{x})}[\ell(a, y)]$ را در نظر بگیرید.

الف: مقدار $\mathbb{E}_{p(y|\mathbf{x})}[\ell(a = -1, y)]$ ، $\mathbb{E}_{p(y|\mathbf{x})}[\ell(a = +1, y)]$ و $\mathbb{E}_{p(y|\mathbf{x})}[\ell(a = 0, y)]$ را به دست آورید.

ب: بر اساس مقادیر به دست آمده در قسمت قبل، رابطه تصمیم‌گیری حداقل تلفات زیر را تکمیل نمایید:

$$a^* = \begin{cases} +1 & \text{if [Fill]} \\ -1 & \text{if [Fill]} \\ 0 & \text{Otherwise} \end{cases}$$

۳ مشتق‌گیری نسبت به پارامترها

مساله طبقه‌بندی را در نظر بگیرید که $\mathbf{x} \in \mathbb{R}^D$ بوده و $y \in \{1, \dots, C\}$ است. در طبقه‌بند رگرسیون لاجستیک چند کلاسه که توزیع احتمال خروجی از رابطه $p(y|\mathbf{x}; \theta) = \text{Cat}(y|\mathcal{S}(\mathbf{W}\mathbf{x}))$ به دست می‌آید، گزینه لگاریتم درست‌نمایی به صورت $\text{NLL}(\mathbf{W}) = \mathbb{H}(\mathbf{y}, \mu)$ محاسبه می‌شود (برای سادگی فرض کردیم تنها یک نمونه آموزشی داریم و از اندیس n صرف‌نظر نموده‌ایم و بردار $\mathbf{y} \in \mathbb{R}^C$ از کدگذاری one-hot خروجی y به دست می‌آید) که $\mu_c = \mathcal{S}(\mathbf{W}\mathbf{x})_c$ است. ماتریس $\frac{\partial \text{NLL}(\mathbf{W})}{\partial \mathbf{W}} \in \mathbb{R}^{C \times D}$ را به دست آورید.

۴ رگرسیون لاجستیک باینری

پایگاه داده $D = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ را در نظر بگیرید. در مدل رگرسیون لاجستیک باینری، توزیع احتمالی پاسخ y به صورت زیر است:

$$p(y=1|\mathbf{x}, \mathbf{w}, b) = \text{Ber}(y|\mu), \quad \begin{cases} \mu = \sigma(a) \\ a = \mathbf{w}^T \mathbf{x} \\ \sigma(x) = \frac{1}{1+e^{-x}} \end{cases}$$

الف: گزینه لگاریتم درست‌نمایی $\text{NLL}(\mathbf{w})$ را برای پایگاه داده D به دست آورید.

ب: شرایطی را تعیین بر حسب مقادیر $\{a_n\}_{n=1}^N$ یا $\{\mu_n\}_{n=1}^N$ تعیین کنید که در آن شرایط پایگاه داده D جداپذیر خطی است.

ج: فرض کنید بردار با طول محدود $\tilde{\mathbf{w}}$ وجود دارد به گونه‌ای که شرایط جداپذیری خطی را دارد. بردار جدید $\hat{\mathbf{w}}$ بر حسب $\tilde{\mathbf{w}}$ را به گونه‌ای معرفی کنید که رابطه زیر برقرار باشد (برقرار رابطه را می‌بایست نشان دهید):

$$\text{NLL}(\hat{\mathbf{w}}) \leq \text{NLL}(\tilde{\mathbf{w}})$$

یادآوری: توزیع دیرپچله یک توزیع برداری برای برداری تصادفی $\mathbf{x} \in \mathbb{R}^n$ است به گونه‌ای که:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \Rightarrow \begin{cases} 0 \leq x_i \leq 1, i = 1, \dots, n \\ \sum_i x_i = 1 \end{cases}$$

تابع چگالی احتمال توزیع دیرپچله یک پارامتر برداری $\alpha \in (\mathbb{R}^+)^n$ دارد که است. متوسط و واریانس هر یک از مولفه‌های بردار تصادفی $\mathbf{x}$ از رابطه زیر به دست می‌آید:

$$\text{Dir}(\mathbf{x}|\alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^n x_i^{\alpha_i-1}, B(\alpha) = \frac{\prod_{i=1}^n \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^n \alpha_i)} \Rightarrow \begin{cases} \mathbb{E}[X_k] = \frac{\alpha_k}{\alpha_0} \\ \text{Var}[X_k] = \frac{\alpha_k(\alpha_0 - \alpha_k)}{\alpha_0^2(\alpha_0 + 1)} \\ \text{Mode}[X_k] = \frac{\alpha_k - 1}{\alpha_0 - n} \end{cases}, \alpha_0 = \sum_{i=1}^n \alpha_i$$

توزیع‌های برنولی و رسته‌ای دارای تابع جرم احتمال زیر هستند:

$$\text{Ber}(y|\theta) = \theta^y (1-\theta)^{1-y}, \quad \begin{cases} y \in \{0, 1\} \\ p \in [0, 1] \end{cases}$$

$$\text{Cat}(\mathbf{y}|\theta) = \prod_{c=1}^C \theta_c^{y_c}, \quad \begin{cases} 0 \leq \theta_c \leq 1 \\ \sum_{c=1}^C \theta_c = 1 \end{cases}$$